

Análise de Desempenho da Inferência de um Modelo de Linguagem Particionado em Múltiplas GPUs

Lucas Fraga Balbinot, Matheus Augusto Tregnago, Rafael Silva de Souza

Objetivo

Analisar o desempenho da inferência distribuída de um LLM particionado em múltiplas GPUs em um cluster com 1 GPU por nó em uma rede Ethernet 1 Gbit/s.

- Comparar Tensor Parallelism vs Pipeline Parallelism, variando numero de nós, hardware de GPU e workload
- Quantificar o custo da comunicação

Trabalhos relacionados

Xu et al., 2025 *Characterizing Communication Patterns in Distributed LLM Inference*

Perfila a comunicação inter-GPU do vLLM com placas H100 em uma rede InfiniBand. TP paga alto custo de rede, mas responde mais rápido em sequências curtas; PP transfere menos dados, porém alonga a latência total.

Topcu et al., 2026 *Parallelization Strategies for Dense LLM Deployment*

Llama-3.1 70B/405B intra-nó: TP favorece latência, PP favorece throughput

Nosso trabalho foca em comparar TP vs PP entre nós com foco na análise de comunicação

O que mudou desde a entrega parcial

- **Nova coleta completa: nsys + iperf3 + sar** além de aiperf e nvidia-smi
- **Varredura de concorrência:** 1 até 32 requisições simultâneas
- **Ajuste na interface de rede da tupi:** Correção no erro da coleta da etapa anterior, que usou uma interface de 100 Mb/s

Ambiente de Teste

- Modelo **Qwen2.5-7B-Instruct**

Nó	GPU	VRAM	Quantidade de nós
tupi	1× RTX 4090	24 GB	1, 2
poti	1× RTX 4070	12 GB	2, 4

Tecnologias utilizadas

- **aiperf**: mede a experiência fim-a-fim: latência, TTFT, ITL, throughput
- **nsys**: separa o tempo de GPU em computação e comunicação
- **iperf3**: mede o teto real do enlace de rede
- **sar**: mostra se a rede satura durante a carga
- **nvidia-smi**: telemetria da GPU: utilização, potência, memória

Design Experimental: Fatorial Completo

Fatorial completo sobre 5 fatores:


Fator	Níveis
nº de GPUs (1 por nó)	1, 2, 4
nó PCAD	tupi, poti
estratégia	none, TP, PP
prompt (entrada/saída)	short 128/128, long 1024/512
tipo de coleta	trace, concurrency

Métricas de Inferência

Principais métricas analisadas:

- **Request Latency:** tempo total do request
- **Time to First Token (TTFT):** latência até primeiro token
- **Inter-Token Latency (ITL):** tempo médio entre tokens
- **Throughput (tokens/s):** taxa de geração


Métricas Inferencia Tupi




Métricas Inferencia Poti

Métricas de inferência — POTI (Short, concorrência = 1)


TP PP




Concorrença Tupi



Concorrência Poti



Utilização da GPU




Utilização da GPU


- Em **TP** a GPU permanece quase **100% ocupada** durante toda a execução
- Mas o kernel que predomina é o **NCCL** (comunicação), não a computação
- GPU única do **tupi** operou em **potência/temperatura mais altas** — esforço concentrado em uma única máquina ⇒ desgaste mais rápido
- **PP** alterna picos de computação entre estágios com **ociosidade** parcial (a "bolha" do pipeline)

Comunicação vs Computação

Comunicação vs. Computação por configuração — Workload Short



Análise de Comunicação




Em **TP** o tráfego atinge o teto de **~0,94 Gbit/s**; em **PP** a rede é subutilizada (~2%). O enlace de 1 GbE é o **gargalo físico** que limita os ganhos do TP.

Trade-offs de Paralelismo

Aspecto	TP	PP
Comunicação	Contínua (<code>AllReduce</code> por camada/token)	Em rajadas (<code>Send/Recv</code> P2P)
Volume	Alto	Baixo (ativações entre estágios)
Saturação do link	Sim (~95%)	Não (~2%)
% de tempo de GPU em NCCL	~53% (N2) → ~81% (N4)	~0-5%
Escalabilidade	Piora com N (comm domina)	Boa com batch (fecha bolha)
Latência em baixa concorrência	Melhor	Pior (bolha)
Throughput em alta concorrência	Limitado (~4×)	Muito superior (~19-22×)

Que rede tornaria TP vantajoso?

Modelo empírico: $TTFT_TP(B) = TTFT_single + K/B$, K calibrado pelo ponto medido em 1 GbE (iperf3 = 0,941 Gb/s).
Ponto onde TP iguala PP é o **break-even**.



Conclusões

Comunicação domina em TP entre nós sobre 1 Gb/s:

- Até **81% do tempo de GPU** em comunicação, com enlace saturado
- TP **piora** com o número de nós.

Quando particionar:

- Se o modelo **cabe em 1 GPU: não particionar**
- **TP**: melhor **latência** em baixa concorrência, mas comm-bound
- **PP**: melhor **throughput** em alta concorrência

Uso de inteligência artificial

Referências

- VASWANI, A. et al. *Attention is All You Need*. 2017.
- XU, L. et al. *Characterizing Communication Patterns in Distributed Large Language Model Inference*. arXiv:2507.14392, 2025.
- TOPCU, B. et al. *Parallelization Strategies for Dense LLM Deployment: Navigating Through Application-Specific Tradeoffs and Bottlenecks*. arXiv:2603.05692, 2026.
- HOCKNEY, R. W. *The communication challenge for MPP: Intel Paragon and Meiko CS-2*. Parallel Computing, 1994.
- NVIDIA. *LLM Inference Benchmarking: Fundamental Concepts*. Disponível em: <https://developer.nvidia.com/blog/llm-benchmarking-fundamental-concepts/>.
- Jarvislabs. *Scaling LLM Inference: Data, Pipeline & Tensor Parallelism in vLLM*. Disponível em: <https://jarvislabs.ai/blog/scaling-llm-inference-dp-pp-tp>.
- KHMEL, P. *LLM inferencing benchmark with vLLM: Tensor Parallel vs Data Parallel*. Disponível em: https://pavlokhmel.com/llm_inferencing_benchmark_with_vllm_benchmark_script_tensor_parallel_vs_data_parallel.html.
- CHINWAG, R. *Demystifying Tensor Parallelism*. 2024. Disponível em: <https://robotchinwag.com/posts/demystifying-tensor-parallelism/>.