

Análise de Desempenho da Inferência de um Modelo de Linguagem Particionado em Múltiplas GPUs

Lucas Fraga Balbinot, Matheus Augusto Tregnago, Rafael Silva de Souza

Ambiente de Teste

Execução realizada no **PCAD (UFRGS)** com diferentes configurações:

- **1 GPU (baseline)** → execução sem comunicação
- **2 GPUs (TP e PP)**
- **4 GPUs (TP e PP)**

Nós utilizados:

- Tupi
- Poti

Modelo Utilizado

- Modelo original (**Llama**) não coube em algumas GPUs
- Substituído por: **Qwen2.5-7B-Instruct**

Motivo:

- Menor footprint de memória
- Permitiu execução em mais configurações
- Manteve representatividade do problema

Organização dos Experimentos

Ordem adotada para análise:

1. **Single GPU (baseline)**
2. **Tensor Parallelism (TP)**
3. **Pipeline Parallelism (PP)**

Objetivo:


- Comparar impacto da comunicação
- Isolar overhead introduzido por paralelismo

Resultados — Métricas de Inferência

Principais métricas analisadas:


- **Request Latency** — tempo total do request
- **Time to First Token (TTFT)** — latência até primeiro token
- **Inter-Token Latency (ITL)** — tempo médio entre tokens
- **Throughput (tokens/s)** — taxa de geração

Request Latency



- Mais máquinas = Tempo maior de comunicação

Time To First Token



- TTFT do TP consideravelmente maior que os dos outros
- Mais nós = Tempo maior

Análise

- Sem comunicação com vantagem nítida
- PP cerca de 7x mais rápido que TP


Explicação:

- Prefill pode ser parcialmente paralelizado
- Pipeline permite início antecipado do processamento

Análise



Output Token Throughput









- 1 GPU apresenta melhor taxa
- Comunicação e número de nós não influenciam muito

Conclusões

- Single GPU vence em todos os casos
- PP é melhor ou igual a TP em todos os casos

Métricas de GPU





Utilização das GPUs


Embora tenha sido mais eficiente no geral, a utilização de apenas 1 GPU pode representar um grande esforço concentrado em apenas uma única máquina, contribuindo para o seu desgaste mais rápido. A sua temperatura e uso de energia foram mais elevados que nos outros casos.

Análise de Comunicação

Comunicação é o principal fator limitante no desempenho. Investigamos:


- **Volume de dados transmitidos**
- **Padrões de comunicação** (burstiness, atividade)
- **Escalabilidade** com aumento de nós

Volume de Comunicação




Volume de dados transmitidos varia significativamente entre configurações e estratégias de paralelismo.

Escalabilidade do Volume de Comunicação




Padrões de Atividade de Comunicação




Intensidade e frequência de comunicação variam entre os experimentos.

Burstiness da Comunicação




Análise do padrão de rajadas (bursts) de comunicação. Indica sincronização e serialização.

Correlação: Burstiness vs Latência




Maior burstiness correlaciona com piores latências na cauda da distribuição.

Throughput da Rede




Utilização da capacidade de rede por experimento.

Throughput por Nó




Desequilíbrio de carga entre nós: alguns subutilizados, outros saturados.

Topologia de Rede




Matriz normalizada mostrando padrões de comunicação entre nós.

Network Throughput Over Time — Short Sequences




Comunicação vs Latência




Relação direta observada entre volume de comunicação e degradação de latência.

Tendências de Escalabilidade



Análise das tendências de escalabilidade com aumento de recursos.

Cumulative Communication Volume — Short Sequences



Achados Principais da Análise de Rede

1. **Volume escalável:** Comunicação cresce com número de nós
2. **Padrão de bursts:** Sincronização cria rajadas intensas de tráfego
3. **Desequilíbrio de carga:** Nós não distribuem carga uniformemente
4. **Latência degradada:** Comunicação introduz overhead significativo
5. **Bottleneck crítico:** Rede limita ganhos de paralelismo

Trade-offs de Paralelismo

Aspecto	TP	PP
Comunicação	Contínua	Em bursts
Volume	Moderado	Variável
Overhead	Menor	Maior
Escalabilidade	Melhor	Limitada

Conclusões

Comunicação é o fator dominante:

- Reduz efetividade do paralelismo
- Domina tempo total de execução
- Impede escalabilidade esperada

Melhor estratégia observada:

- Single GPU quando possível (sem comunicação)
- PP preferível a TP quando paralelismo necessário
- Escalabilidade limitada por rede

Limitações e Desafios

- Acesso limitado a algumas máquinas
- Inconsistência de recursos entre nós
- Presença de segredos em logs
- Ajuste manual de experimentos distribuídos
- Largura de banda de rede limitada em PCAD

Ferramentas e Metodologia

- Python (pandas, matplotlib, seaborn) para análise
- Jupyter Notebooks para visualização
- nvidia-smi para coleta de telemetria
- Slurm para execução em cluster
- Git para controle de versão
- Nsight Systems para profiling GPU

Boas Práticas Adotadas

- Scripts reprodutíveis
- Separação clara entre dados, código e resultados
- Controle de versões com Git
- Visualizações padronizadas
- Documentação de procedimentos