Entrega Parcial

Lucas Fraga Balbinot, Matheus Augusto Tregnago, Rafael Silva de Souza

UFRGS — CMP223 — Análise de Desempenho

Ambiente de Teste

Execução realizada no **PCAD (UFRGS)** com diferentes configurações:

- **1 GPU (baseline)** → execução sem comunicação
- **2 GPUs (TP e PP)**
- **4 GPUs (TP e PP)**

Nós utilizados:

- Tupi (principal)
- Poti (distribuído)
- Experimento adicional em máquina única

Ajuste de Modelo

- Modelo original (**Llama**) não coube em algumas GPUs
- Substituído por:

Qwen2.5-7B-Instruct

Motivo:

- Menor footprint de memória
- Permitiu execução em mais configurações
- Manteve representatividade do problema

Organização dos Experimentos

Ordem adotada para análise:

1. **Single GPU (baseline)**
2. **Tensor Parallelism (TP)**
3. **Pipeline Parallelism (PP)**

Objetivo:

- Comparar impacto da comunicação
- Isolar overhead introduzido por paralelismo

Resultados — Visão Geral

Principais métricas analisadas:

- **Request Latency**
- **Time to First Token (TTFT)**
- **Inter-Token Latency (ITL)**
- **Throughput (tokens/s)**

Observação geral:

- Mais hardware ≠ melhor desempenho

Request Latency

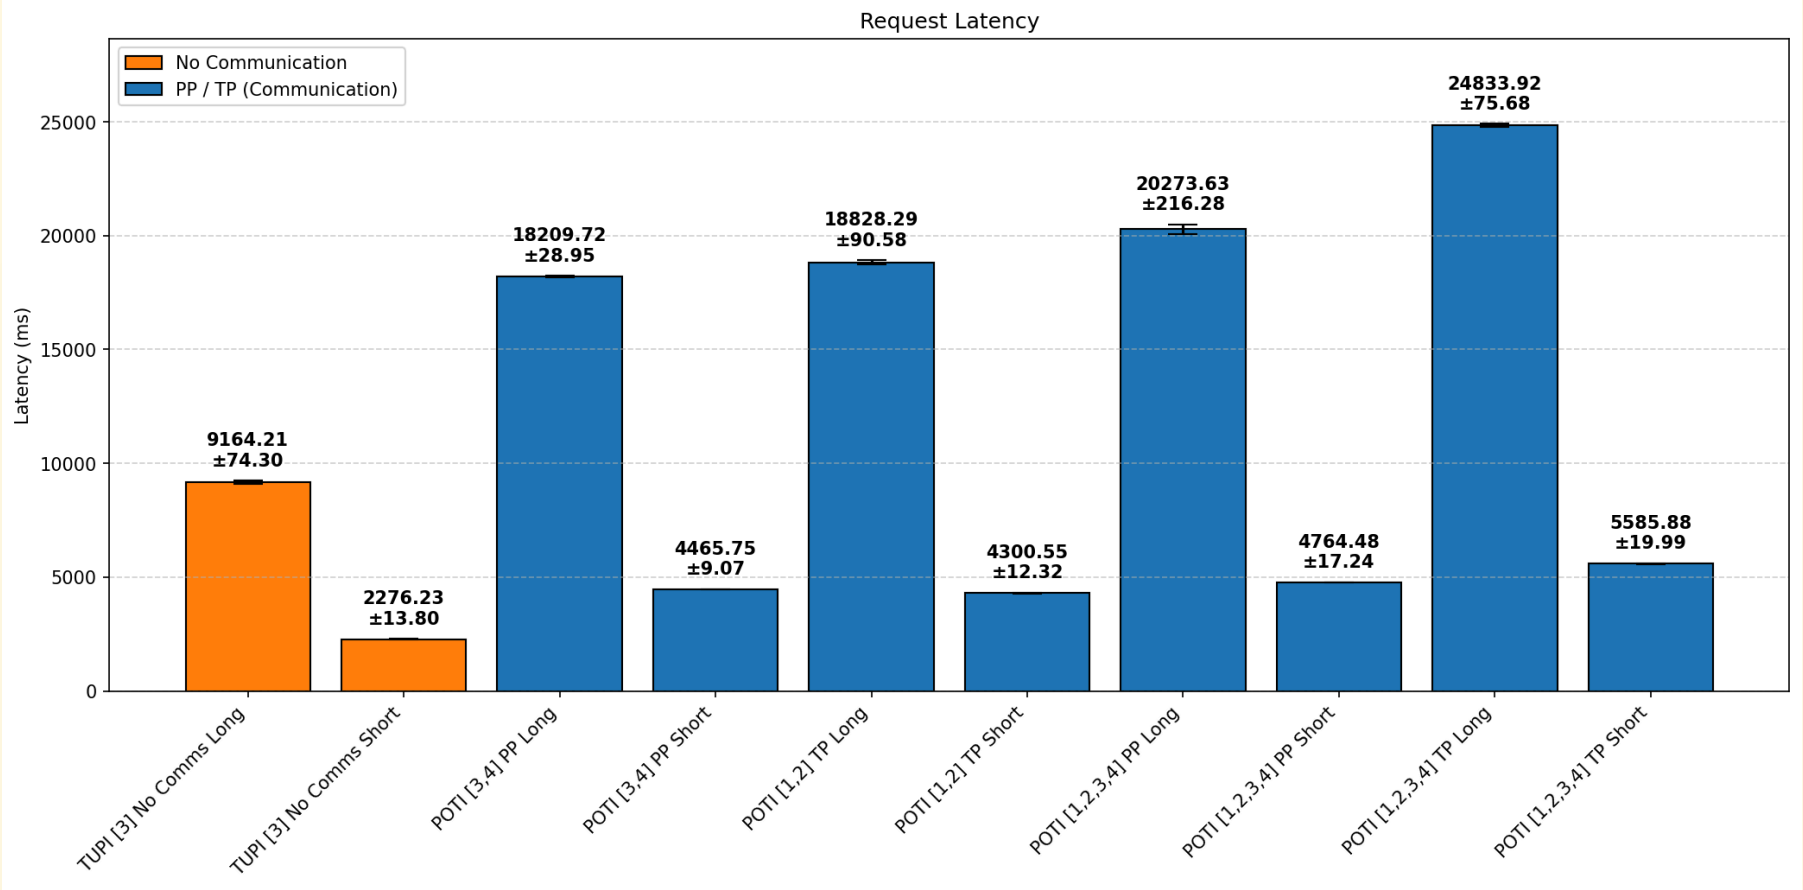

- Mais máquinas = Tempo maior de comunicação

Time To First Token

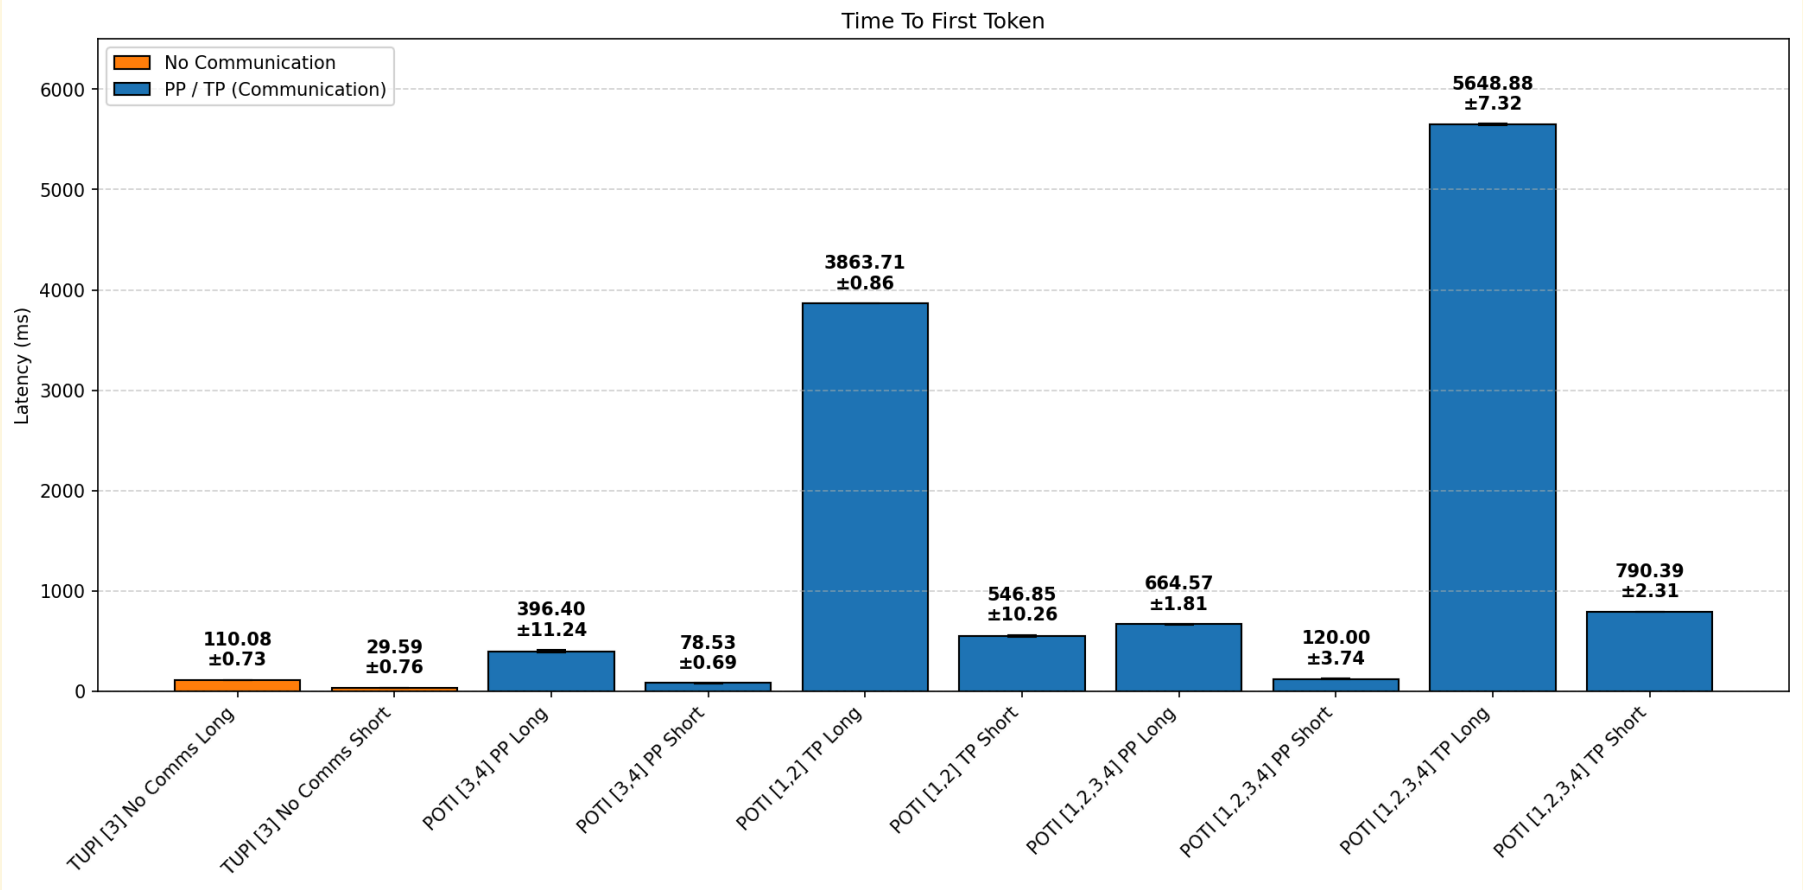

- TTFT do TP consideravelmente maior que os dos outros

Inter Token Latency

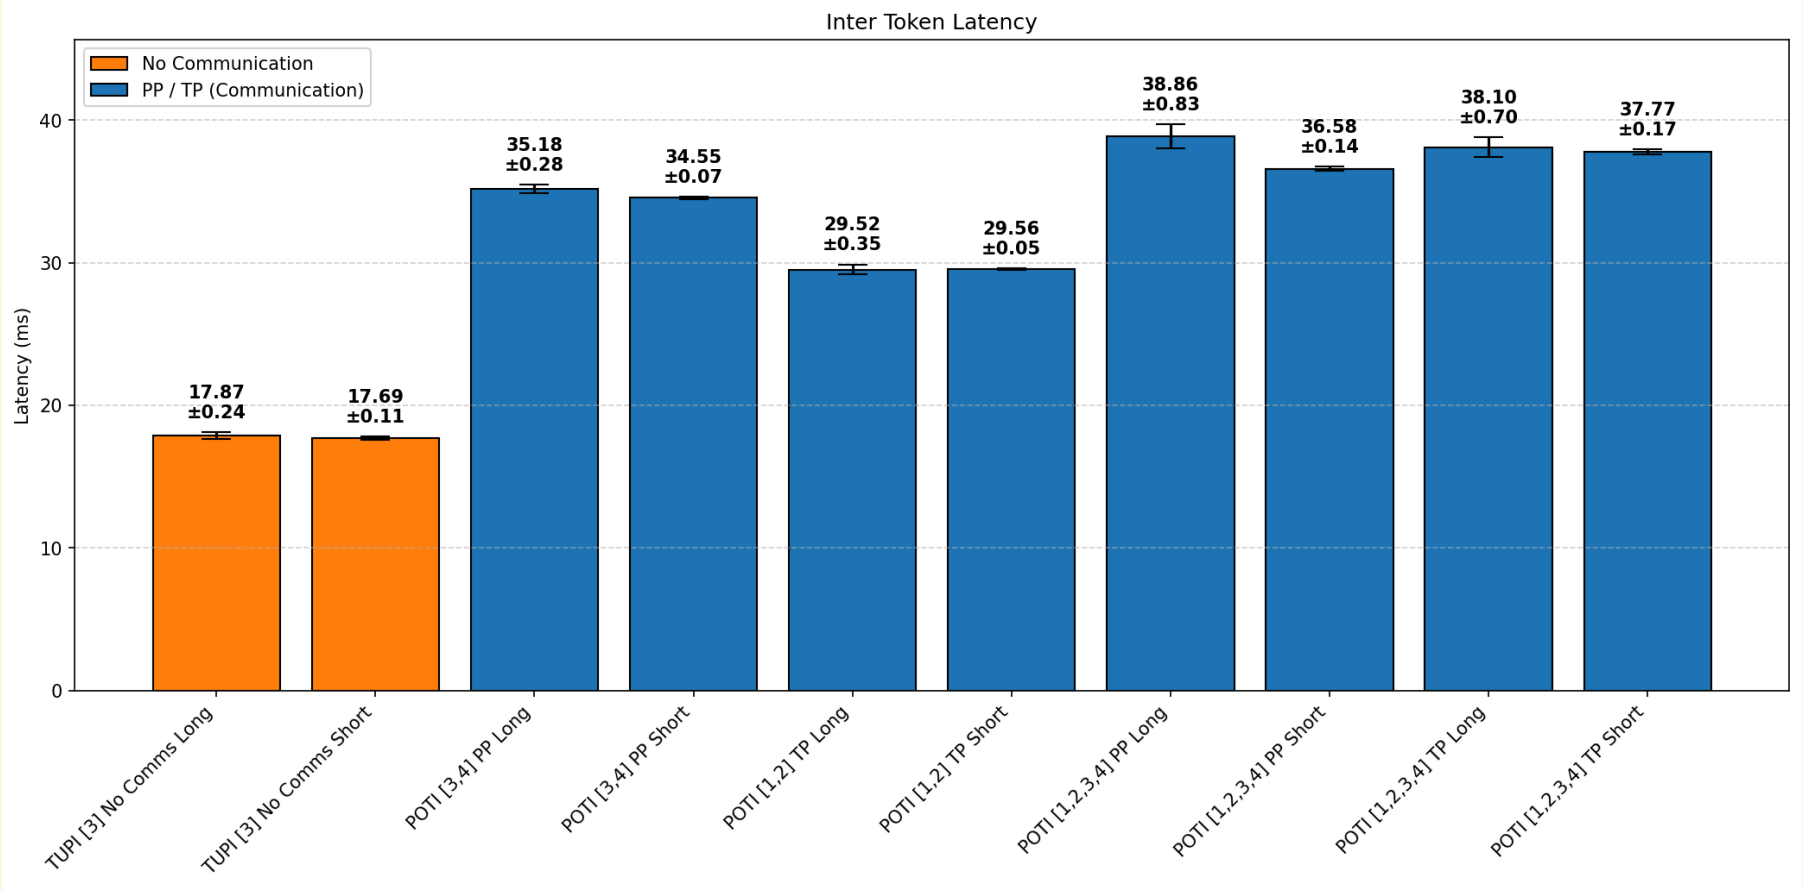

- TP com o menor tempo entre aqueles com comunicação

Output Token Throughput

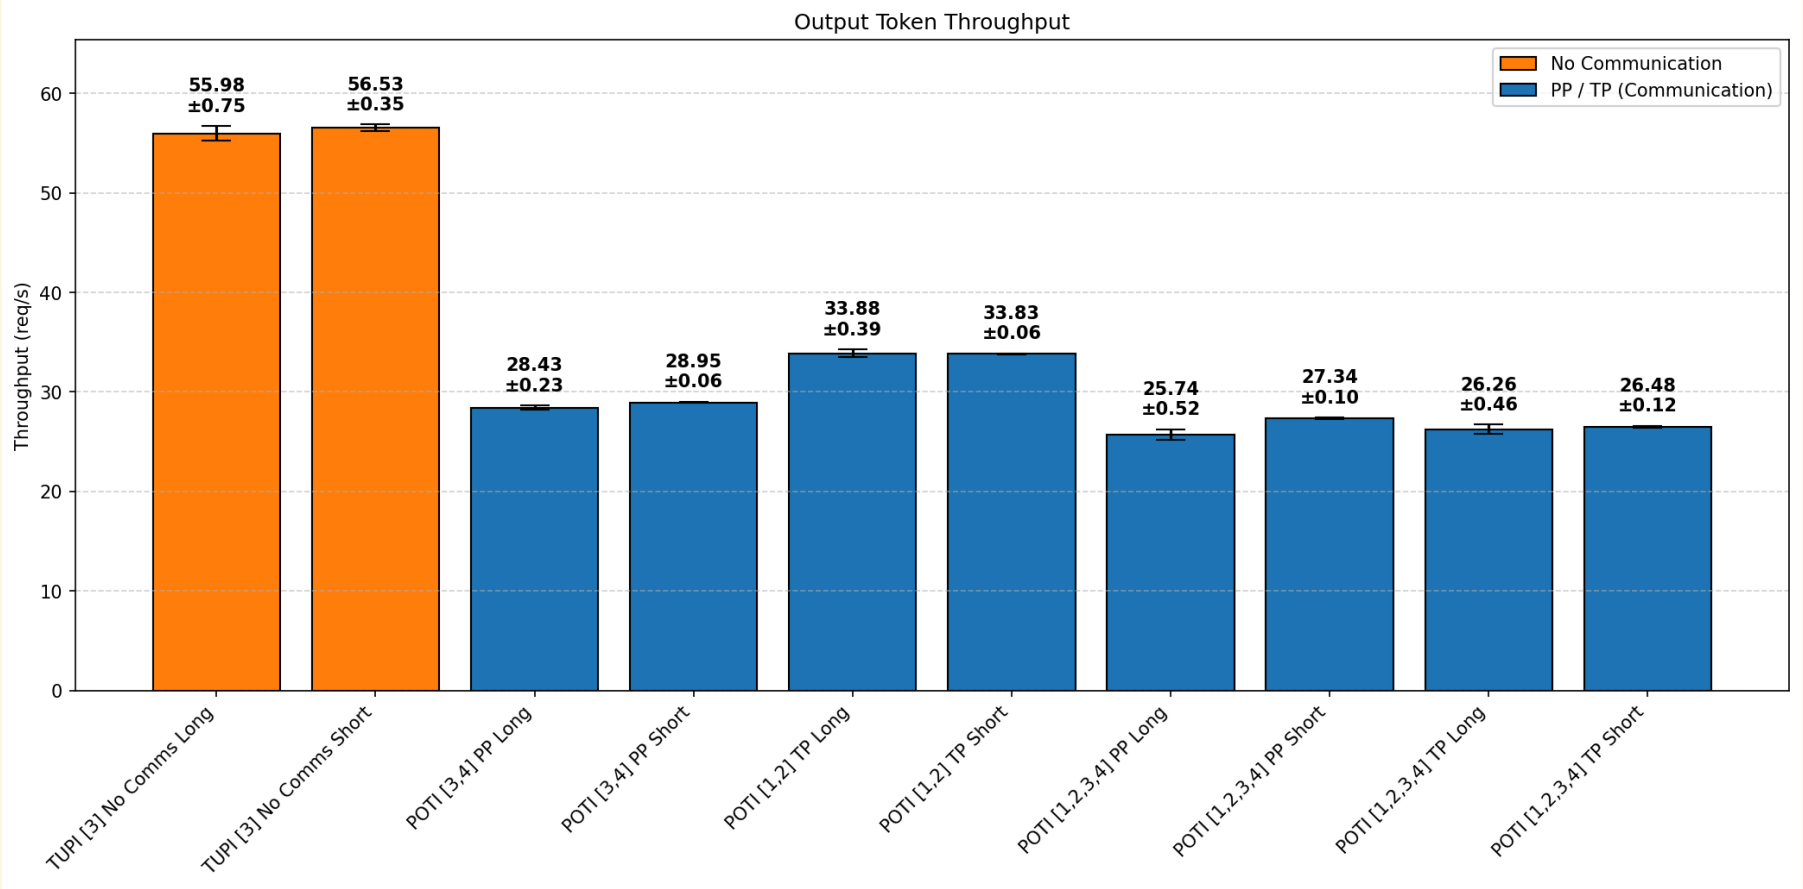

- 1 GPU mais rápida

Análise — Inter-Token Latency

Resultados típicos:

- **Single GPU:** ~16 ms
- **TP:** intermediário
- **PP:** ~33 ms

Interpretação:

- ITL é altamente sensível à comunicação
- PP sofre com sincronização entre estágios

Análise — Time to First Token (TTFT)

Resultado contraintuitivo:

- **PP apresentou TTFT até 10x menor**

Explicação:

- Prefill pode ser parcialmente paralelizado
- Pipeline permite início antecipado do processamento

Conclusão:

- PP favorece início rápido, mas penaliza execução contínua

Trade-off Fundamental

Existe um conflito claro:

Métrica	Melhor abordagem
TTFT	Pipeline Parallelism
ITL	Single GPU
Latência total	Single GPU
Utilização GPU	Tensor Parallelism

Comunicação como Gargalo

Diferença principal entre cenários:

- **Sem comunicação:** execução local → mais eficiente
- **Com comunicação:**
  - sincronização
  - transferência de dados
  - latência de rede

Comunicação domina o custo total

Métricas de GPU

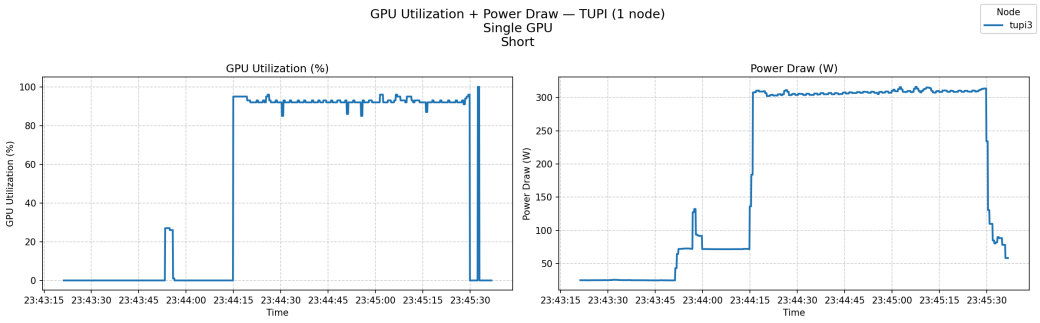

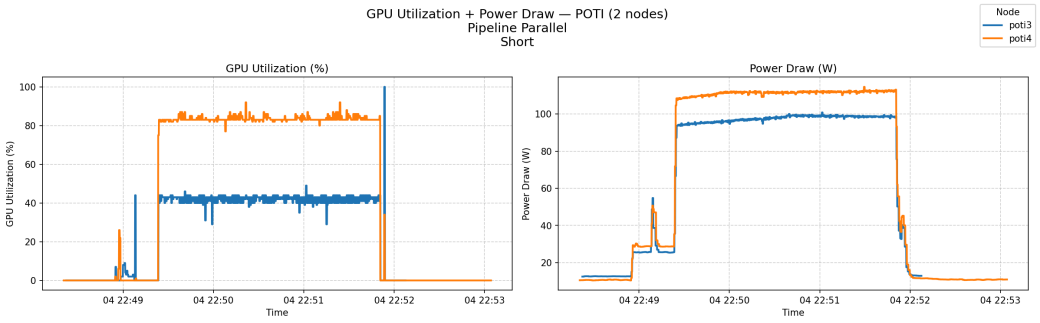

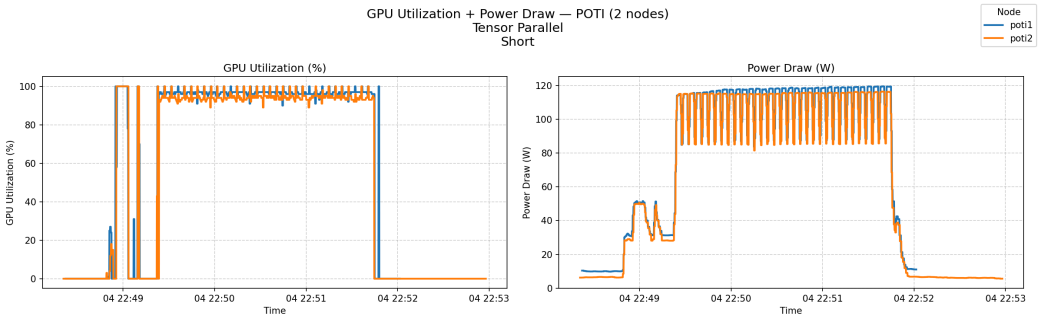

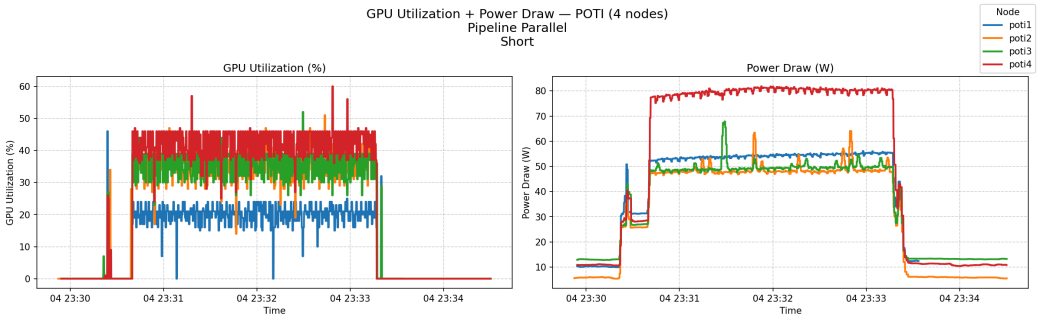

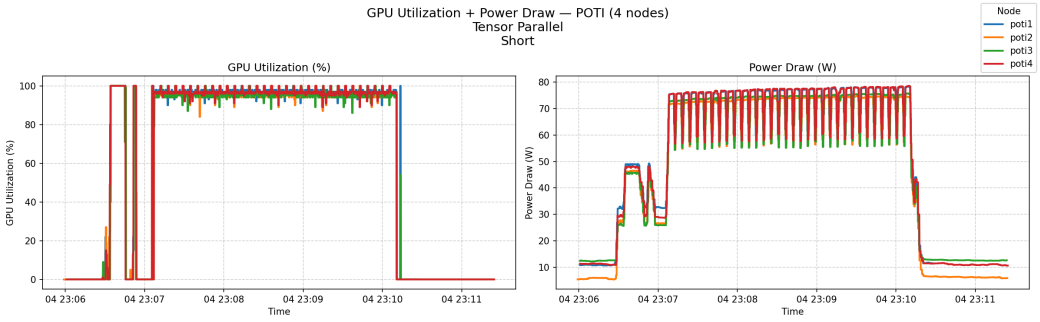

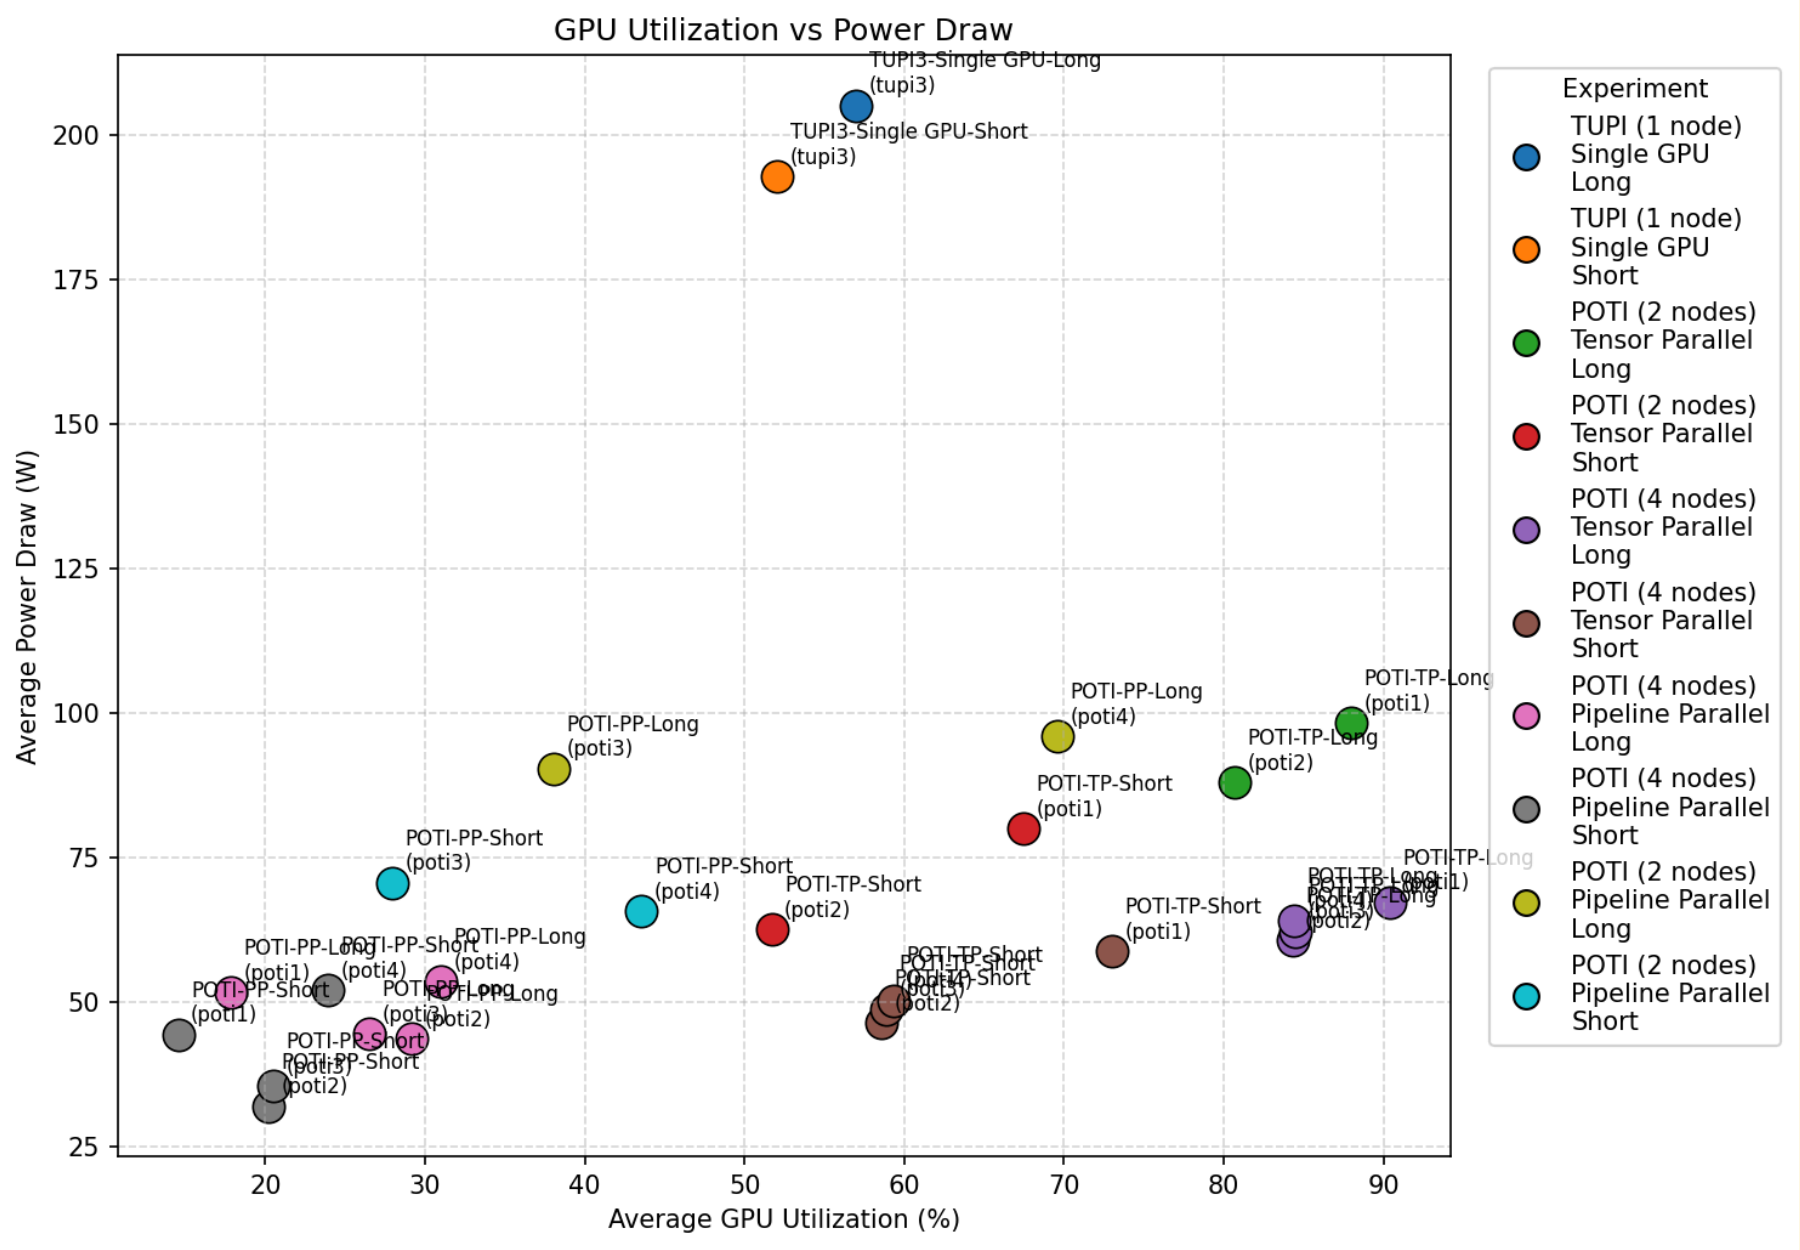
GPU Utilization vs Power Draw
Average Power Draw (W)
Average GPU Utilization (%)
TUPI3-Single GPU-Long (tupi3)
TUPI3-Single GPU-Short (tupi3)
POTI-PP-Long (poti4)
POTI-TP-Long (poti1)
POTI-TP-Long (poti2)
POTI-PP-Long (poti3)
POTI-TP-Short (poti1)
POTI-PP-Short (poti3)
POTI-PP-Short (poti4)
POTI-TP-Short (poti2)
POTI-TP-Short (poti1)
POTI-PP-Long (poti1)
POTI-PP-Short (poti4)
POTI-PP-Long (poti4)
POTI-PP-Short (poti1)
POTI-PP-Short (poti2)
Experiment
TUPI (1 node) Single GPU Long
TUPI (1 node) Single GPU Short
POTI (2 nodes) Tensor Parallel Long
POTI (2 nodes) Tensor Parallel Short
POTI (4 nodes) Tensor Parallel Long
POTI (4 nodes) Tensor Parallel Short
POTI (4 nodes) Pipeline Parallel Long
POTI (4 nodes) Pipeline Parallel Short
POTI (2 nodes) Pipeline Parallel Long
POTI (2 nodes) Pipeline Parallel Short

Resultado Principal

Single GPU apresentou melhor desempenho geral

- Menor **latência total**
- Melhor **inter-token latency**
- Maior **throughput efetivo**

Interpretação:

- Ausência de comunicação elimina overhead

Tensor Parallelism (TP)

Características observadas:

- GPUs próximas de **100% de utilização**
- Boa distribuição de carga
- Overhead moderado de comunicação

Impacto:

- Latência maior que baseline
- Ainda eficiente em comparação com PP

Pipeline Parallelism (PP)

Comportamento identificado:

- Uma GPU ~**40–50%**
- Outra GPU ~**90–100%**

Problema:

- **Desbalanceamento de pipeline**
- Execução parcialmente sequencial

Consequência:

- Maior latência total
- Pior inter-token latency

Utilização das GPUs

Embora tenha sido mais eficiente no geral, a utilização de apenas 1 GPU pode representar um grande esforço concentrado em apenas uma única máquina, contribuindo para o seu desgaste mais rápido. A sua temperatura e uso de energia foram mais elevados que nos outros casos.

Dificuldades Encontradas

- Acesso limitado a algumas máquinas
- Inconsistência de recursos entre nós
- Presença de **tokens sensíveis em logs** (bloqueio de push)
- Ajuste manual de experimentos distribuídos

Soluções Aplicadas

- Troca de modelo (Qwen)
- Limpeza de logs e remoção de segredos
- Organização dos dados experimentais
- Padronização de métricas e scripts

Boas Práticas Adotadas

- Uso de **scripts reprodutíveis**
- Separação clara entre:
  - dados
  - código
  - resultados
- Controle de versões com Git
- Visualizações padronizadas

Ferramentas Utilizadas

- Python (pandas, matplotlib, seaborn)
- Jupyter Notebooks
- nvidia-smi (telemetria)
- Slurm (execução no cluster)
- Git + GitHub

Conclusão Parcial

- Comunicação é o principal fator limitante
- Mais GPUs nem sempre melhoram desempenho
- TP é mais eficiente que PP no cenário analisado
- Single GPU ainda é o melhor baseline quando possível

Próximos Passos

- Refinar medição de **tempo de comunicação**
- Separar claramente:
  - prefill vs decode
- Melhorar balanceamento no pipeline
- Avaliar escalabilidade com mais nós

Avaliação do Progresso

Ambiente definido
Métricas coletadas
Resultados consistentes
Gargalos identificados

Status: progresso consistente e metodologia validada