

Análise de Desempenho da Inferência de um Modelo de Linguagem Particionado em Múltiplas GPUs

Lucas Fraga Balbinot, Matheus Augusto Tregnago, Rafael Silva de Souza

Universidade Federal do Rio Grande do Sul – Instituto de Informática CMP223 – Análise de
Desempenho de Sistemas Computacionais

Mudanças: Ajuste de Modelo

- Modelo original **Llama 3.1 8B** foi substituído pelo **Qwen2.5-7B-Instruct**

Motivo:

- Menos uso de memória
- Permitiu execução em mais configurações
- Manteve representatividade do problema

Mudanças: Ambiente de Teste

- **1 GPU** → Nó **tupi**
- **2 GPUs** → Nós **tupi** ou **poti**
- **4 GPUs** → Nó **poti**

Nó	GPU	VRAM	Nº de nós usados	CPU
tupi	1× RTX 4090	24 GB	1, 2	Intel(R) Core(TM) i9-14900KF
poti	1× RTX 4070	12 GB	2, 4	Intel(R) Core(TM) i7-14700KF

Mudanças: Tecnologias

Originalmente, o particionamento seria implementado usando ferramentas do ecossistema do **PyTorch**.

Optamos por utilizar **Ray Cluster** e **vLLM**:

- **vLLM**: TP e PP nativos
- **Ray**: orquestra os *workers* entre nós PCAD, abstraindo a descoberta dos nodos e suas GPUs.

Estratégias de Particionamento

Tensor Parallelism (TP) – *fatiamento horizontal*

- Cada camada é dividida entre as GPUs (matrizes fatiadas por linhas/colunas)
- Sincronização via **all-reduce** após cada camada
- Aumenta capacidade de memória e throughput de cálculo
- **Custo:** comunicação intensa a cada camada

Pipeline Parallelism (PP) – *fatiamento vertical*

- Conjuntos de camadas são distribuídos sequencialmente entre GPUs
- Cada GPU passa ativações ao próximo estágio
- Comunicação **menor** (só nas fronteiras dos estágios)
- **Custo:** potencial desbalanceamento na distribuição das camadas

Organização dos Experimentos

Projeto gerado com a biblioteca `pyDOE3`.

Fatores e níveis:

Fator	Níveis
<code>n_gpus</code>	1, 2, 4
<code>no_pcad</code>	tupi, poti
<code>estrategia</code>	none (single), TP, PP
<code>prompt</code>	short (128/128), long (1024/512)

Resultados – Visão Geral


Principais métricas analisadas:

- **Request Latency**
- **Time to First Token (TTFT)**
- **Inter-Token Latency (ITL)**
- **Throughput (tokens/s)**

Observação geral:


- Mais hardware $\neq$ melhor desempenho

Request Latency




- Mais máquinas = Tempo maior de comunicação

Time To First Token




- TTFT do TP consideravelmente maior que os dos outros
- **Tupi N=2 com TP:** provável gargalo de rede entre nós

Inter Token Latency



- TP e PP com ITL similar no poti; TP leve vantagem em N=2
- **Tupi N=2:** TP ~72 ms vs PP ~21 ms. Penalizado pela rede

Output Token Throughput



- 1 GPU mais rápida

Análise — Inter-Token Latency

Resultados típicos:

- **Single GPU:** ~18 ms
- **TP:** ~30–38 ms
- **PP:** ~35–39 ms

Interpretação:

- ITL é altamente sensível à comunicação
- TP e PP se sobrepõem; estratégia importa menos que presença de comunicação

Análise — Time to First Token (TTFT)

Resultado contraintuitivo:

- **PP apresentou TTFT até 10x menor**

Explicação:

- Prefill pode ser parcialmente paralelizado
- Pipeline permite início antecipado do processamento

Conclusão:

- PP favorece início rápido, mas penaliza execução contínua

Trade-off Fundamental

Existe um conflito claro:

Métrica	Melhor abordagem
TTFT	Pipeline Parallelism
ITL	Single GPU
Latência total	Single GPU
Throughput tokens	Tensor Parallelism


Comunicação como Gargalo

Diferença principal entre cenários:

- **Sem comunicação:** execução local → mais eficiente
- **Com comunicação:**
 - sincronização
 - transferência de dados
 - latência de rede


Comunicação domina o custo total

Telemetry GPU – Single (N1, tupi)




Telemetry GPU – TP

N=2 (poti)




N=4 (poti)




Telemetry GPU – PP

N=2 (poti)



N=4 (poti)



Resultado Principal

Single GPU apresentou melhor desempenho geral

- Menor **latência total**
- Melhor **inter-token latency**
- Maior **throughput efetivo**

Interpretação:

- Ausência de comunicação elimina overhead

Tensor Parallelism (TP)

Características observadas:

- GPUs próximas de **100% de utilização**
- Boa distribuição de carga
- Overhead moderado de comunicação

Impacto:

- Latência maior que baseline
- Maior throughput de geração após o prefill

Pipeline Parallelism (PP)

Comportamento identificado:

- Uma GPU ~**40–50%**
- Outra GPU ~**90–100%**

Problema:

- **Desbalanceamento de pipeline**
- Execução parcialmente sequencial

Consequência:

- TTFT muito menor que TP
- Menor throughput de geração sustentado

Utilização das GPUs

Embora tenha sido mais eficiente no geral, a utilização de apenas 1 GPU pode representar um grande esforço concentrado em apenas uma única máquina, contribuindo para o seu desgaste mais rápido. A sua temperatura e uso de energia foram mais elevados que nos outros casos.

Dificuldades Encontradas

Disponibilidade e compatibilidade dos nós PCAD:

- **beagle** — incompatibilidade de drivers do CUDA com vLLM;
- **cidia** — memória das GPUs não suportava o particionamento do modelo;
- **tupi com 4 nós** — falta de disponibilidade simultânea no PCAD;

Conclusão Parcial

- Comunicação é o principal fator limitante
- Mais GPUs nem sempre melhoram desempenho
- Single GPU ainda é o melhor baseline quando possível

Próximos Passos

- Verificar a configuração da rede de comunicação entre os nós `tupi`
- Coletar métricas de rede
- Analisar a influência da concorrência de requisições na inferencia
- Coletar métricas mais detalhadas sobre o uso das GPUs (nsys)

Referências

- VASWANI, A. et al. *Attention is All You Need*. 2017.
- BOMMASANI, R. et al. *On the Opportunities and Risks of Foundation Models*. 2021.
- PASZKE, A. et al. *PyTorch: An Imperative Style Deep Learning Library*. 2019.
- NVIDIA. *CUDA C Programming Guide*. 2023.
- NVIDIA. *LLM Inference Benchmarking: Fundamental Concepts*.
<https://developer.nvidia.com/blog/llm-benchmarking-fundamental-concepts/>
- NVIDIA. *NIM LLM Benchmarking Guide*.
<https://docs.nvidia.com/nim/benchmarking/llm/latest/index.html>
- NVIDIA. *DCGM User Guide – Metrics*. <https://docs.nvidia.com/datacenter/dcgmlatest/user-guide/feature-overview.html>
- PCAD. <https://gppd-hpc.inf.ufrgs.br/>
- Chinwag, R. *Demystifying Tensor Parallelism*. 2024.
<https://robotchinwag.com/posts/demystifying-tensor-parallelism/>