Análise de Desempenho da Inferência de um Modelo de Linguagem Distribuído em Múltiplas GPUs

Rafael Silva de Souza
Matheus Augusto Tregnago
Lucas Fraga Balbinot

Universidade Federal do Rio Grande do Sul
Instituto de Informática

Motivação

Modelos de linguagem de grande porte (LLMs) tornaram-se essenciais em diversas aplicações de IA:

- Assistentes virtuais
- Sistemas de diálogo
- Tradução automática
- Geração de texto

Esses modelos possuem **bilhões de parâmetros**, exigindo grande capacidade computacional.

Objeto Computacional

Execução da inferência do modelo Llama 3.1 8B com PyTorch e CUDA no ambiente PCAD da UFRGS.

A análise será feita por medição do desempenho em diferentes GPUs, considerando métricas como latência, throughput e utilização de recursos.

Os dados serão obtidos por experimentos controlados, variando parâmetros como tamanho do prompt e número de tokens gerados.

Modelos de Linguagem Modernos

LLMs modernos são baseados na arquitetura **Transformer**.

Principais características

- Uso de **mecanismos de atenção (attention)**
- Processamento paralelo de sequências
- Escalabilidade para bilhões de parâmetros

Problema

A execução de modelos grandes apresenta desafios:

- Alto consumo de memória
- Grande número de operações matriciais
- Necessidade de **alto paralelismo computacional**

Mesmo durante **inferência**, o custo computacional é elevado.

O que é Inferência?

Inferência é o processo de **utilizar um modelo já treinado para gerar uma saída**.

Etapas principais:

1. Entrada de texto (prompt)
2. Tokenização
3. Execução das camadas do modelo
4. Predição do próximo token
5. Geração da resposta

Por que usar GPUs?

GPUs são ideais para aprendizado profundo porque:

- Executam **operações matriciais em paralelo**
- Possuem alta largura de banda de memória
- São otimizadas para álgebra linear

Bibliotecas utilizadas:

- CUDA
- cuBLAS
- PyTorch

Modelo Utilizado

Modelo analisado:

Llama 3.1 8B

Características:

- Aproximadamente **8 bilhões de parâmetros**
- Arquitetura Transformer
- Aplicações em processamento de linguagem natural

Ambiente Experimental

Experimentos realizados no ambiente:

PCAD – Plataforma de Computação de Alto Desempenho

Infraestrutura:

- GPUs NVIDIA
- CUDA
- Ferramentas de profiling

GPUs utlizadas

Planeja-se utilizar diferentes GPUs para verificar suas métricas e compará-las.

Nós previstos:

- Beagle – nó com duas GPUs de menor capacidade computacional
- Tupi – nó com 2 a 3 GPUs de alto desempenho
- Grace – nó com uma GPU com memória suficiente para execução completa do modelo, utilizada como baseline

Ferramentas de Análise

Ferramentas utilizadas para coleta de métricas:

- NVIDIA Nsight Systems
- NVIDIA Nsight Compute
- nvidia-smi

Essas ferramentas permitem observar:

- utilização da GPU
- tempo de execução de kernels CUDA
- uso de memória

Métricas de Desempenho

Latência

Tempo total para gerar uma resposta:

$$\text{latency} = T_{end} - T_{start}$$

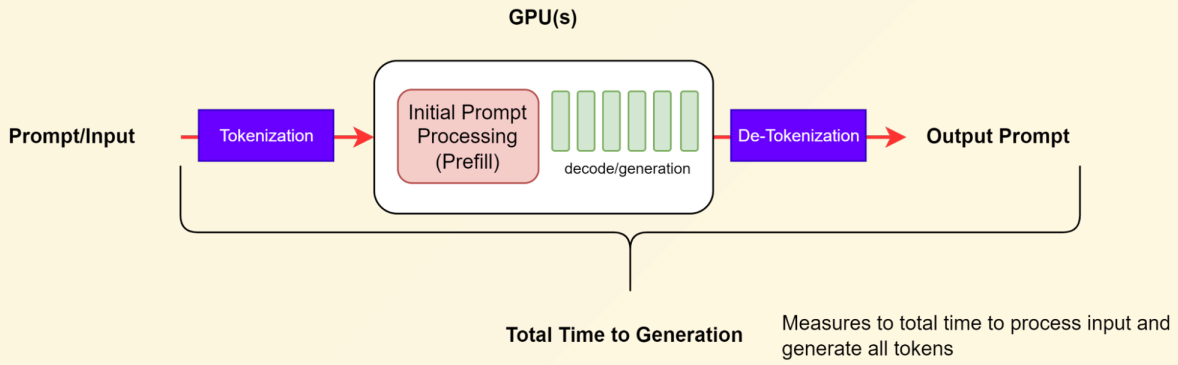

Tokens per Second

Número de tokens gerados por segundo:

TPS = Total_output_tokens / (T_{end} - T_{start})

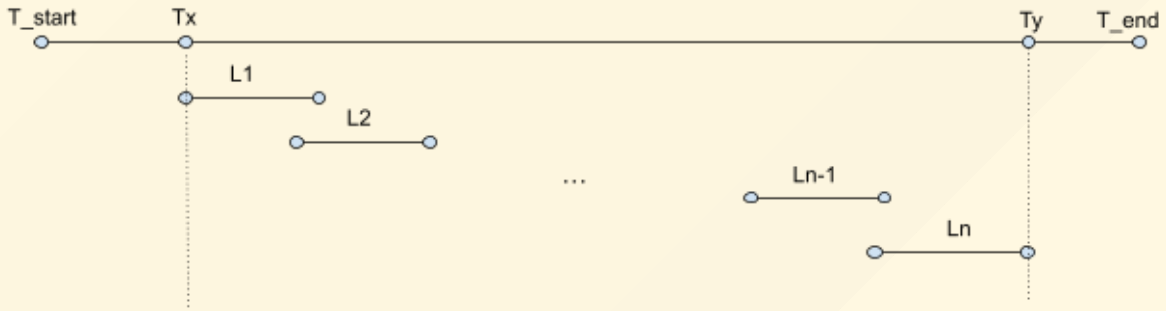

Time to First Token

Tempo até o primeiro token.

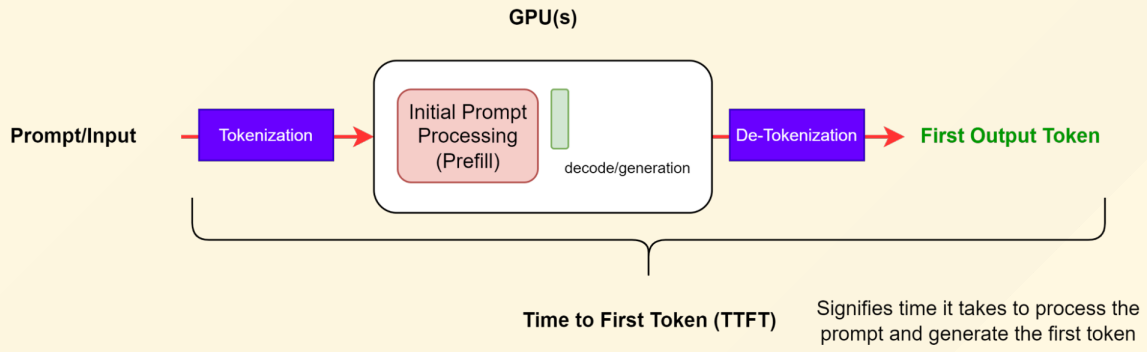

Métricas de GPU

Serão analisados:

- utilização da GPU
- uso de memória
- largura de banda de memória
- tempo de execução de kernels CUDA

Escalabilidade

Para avaliar o paralelismo será medido o **speedup**:

Speedup(N) = T(1) / T(N)

onde:

- T(1) = tempo usando 1 GPU
- T(N) = tempo usando N GPUs

Eficiência Paralela

A eficiência do paralelismo será calculada por:

Efficiency(N) = Speedup(N) / N

Permite avaliar se o uso de múltiplas GPUs é eficiente.

Planejamento Experimental

Parâmetros analisados:

- número de GPUs
- tamanho do prompt
- número de tokens gerados
- tamanho do batch de inferência

Cada experimento será repetido várias vezes para reduzir variabilidade.

Resultados Esperados

Espera-se identificar:

- gargalos de execução
- impacto do paralelismo em GPUs
- limites de escalabilidade do modelo

Contribuições

Este trabalho busca contribuir para:

- melhor compreensão da execução de **LLMs em HPC**
- análise de desempenho de inferência
- otimização de execução em múltiplas GPUs

Obrigado!

Referências

https://developer.nvidia.com/blog/llm-benchmarking-fundamental-concepts/
https://docs.nvidia.com/nim/benchmarking/llm/latest/index.html
https://gppd-hpc.inf.ufrgs.br/