Análise de Desempenho da Inferência de um Modelo de Linguagem Particionado em Múltiplas GPUs

Alunos: Lucas Fraga Balbinot, Matheus Augusto Tregnago, Rafael Silva de Souza

Universidade Federal do Rio Grande do Sul — Instituto de Informática
CMP223 — Análise de Desempenho de Sistemas Computacionais

Motivação

Modelos de linguagem de grande porte (LLMs) tornaram-se essenciais em aplicações de IA como assistentes virtuais, tradução automática e geração de código.

Esses modelos possuem **bilhões de parâmetros**, exigindo grande capacidade computacional, mesmo apenas para **inferência**.

Problema central: o modelo frequentemente **não cabe na memória de uma única GPU**, exigindo **particionamento entre múltiplas GPUs**, o que introduz overhead de comunicação e afeta o desempenho.

Objeto Computacional

Execução da **inferência** do modelo **Llama 3.1 8B** no ambiente **PCAD** da UFRGS.

- ~8 bilhões de parâmetros
- ~16 GB de pesos

O que é Inferência?

Inferência é o processo de utilizar um modelo já treinado para gerar texto a partir de um prompt.

Duas fases com características computacionais distintas:

1. **Prefill** — processa todo o prompt de entrada em paralelo
2. **Decode** — gera tokens de saída um por vez, de forma autorregressiva

Por que GPUs?

GPUs são ideais para inferência de LLMs porque executam **milhares de operações matriciais em paralelo** e possuem **alta largura de banda de memória**.

Biblioteca	Função
CUDA	Runtime e gerenciamento de kernels na GPU
cuBLAS	Multiplicações de matrizes otimizadas
NCCL	Comunicação entre múltiplas GPUs
PyTorch	Framework de deep learning

Durante a inferência, o PyTorch dispara **kernels cuBLAS** para as multiplicações de matrizes de cada camada do modelo.

Ambiente Experimental — PCAD/UFRGS

PCAD – Parque Computacional de Alto Desempenho

Mantido pelo LPPD (Laboratório de Processamento Paralelo e Distribuído), vinculado ao Instituto de Informática da UFRGS.

- Mais de **1.000 núcleos de CPU** e **100.000 CUDA threads**
- Mais de **40 nós computacionais** com configurações heterogêneas
- Gerenciador de filas **Slurm** para submissão de jobs
- Acesso remoto via **SSH**: `gppd-hpc.inf.ufrgs.br`

Nós de processamento selecionados

- **Grace**: VRAM suficiente para o modelo completo **sem particionamento**
- **Tupi**: GPU moderna; testes em **múltiplas máquinas**
- **Beagle**: Duas GPUs em uma **mesma máquina**

Nó	GPU	VRAM
grace	1 × NVIDIA L40S	46 GB
tupi	1 × GeForce RTX 4090	24 GB
beagle	2 × GeForce GTX 1080 Ti	11 GB

Métricas de Inferência

- **TTFT**: Tempo até o primeiro token
- **ITL**: Tempo médio entre tokens consecutivos
- **E2E Latency**: Tempo total do request
- **TPS**: Tokens gerados por segundo (sistema)

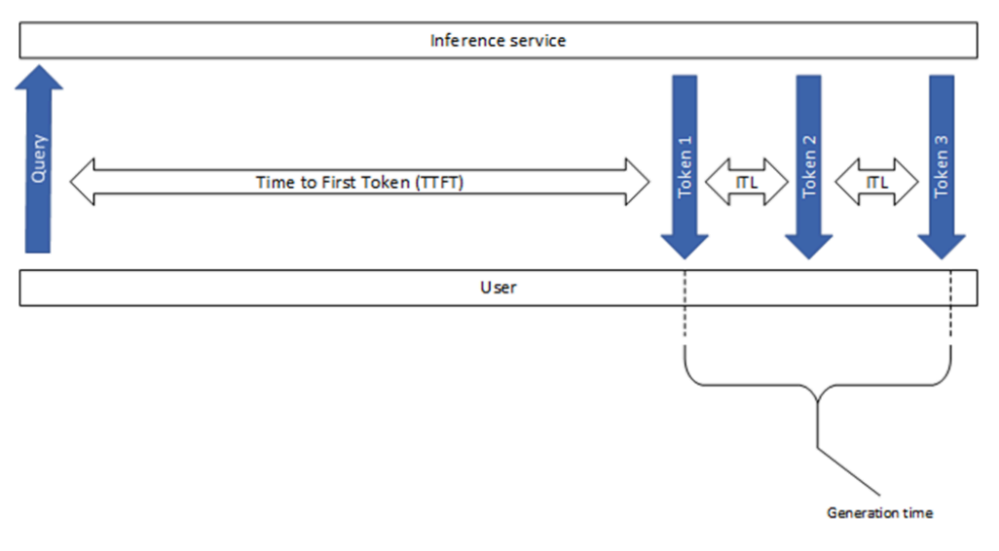

Time to First Token (TTFT)

Tempo entre o envio do prompt e o recebimento do **primeiro token** gerado:

$$\mathrm{TTFT} = T_{\mathrm{first_token}} - T_{\mathrm{request}}$$

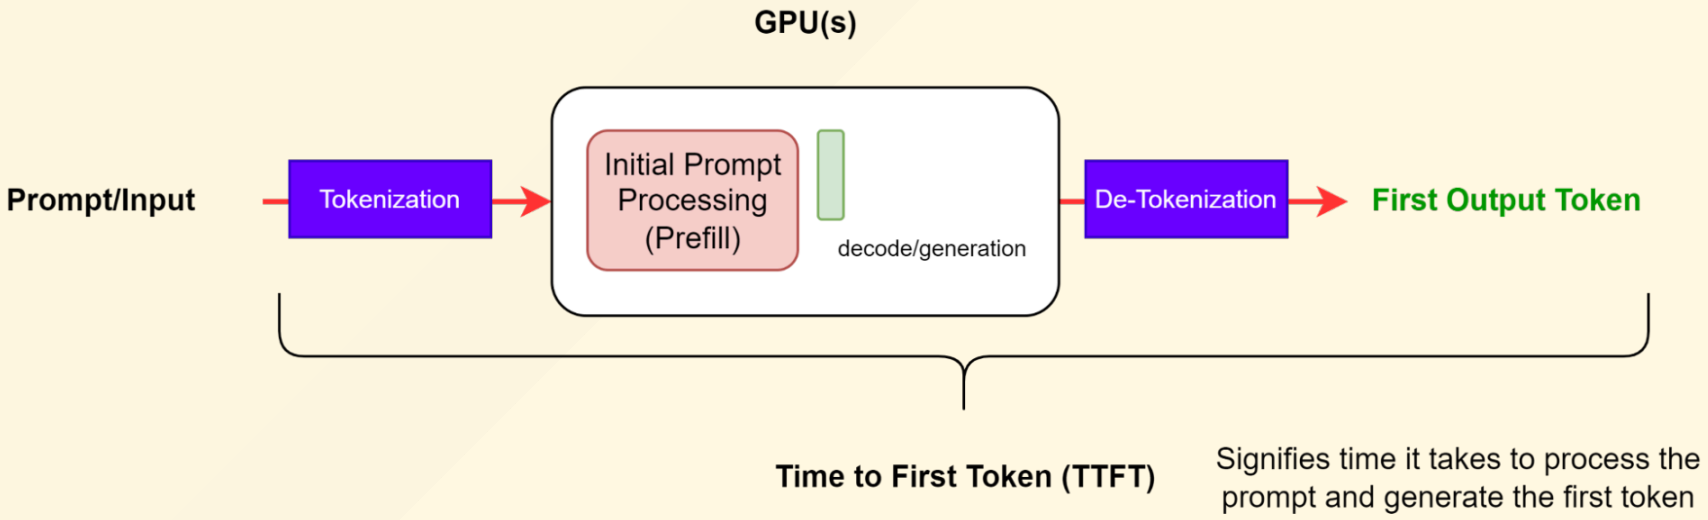

Latência End-to-End

Tempo total para processar o prompt e gerar a **resposta completa**:

$$\text{e2e_latency} = \text{TTFT} + \text{generation_time}$$

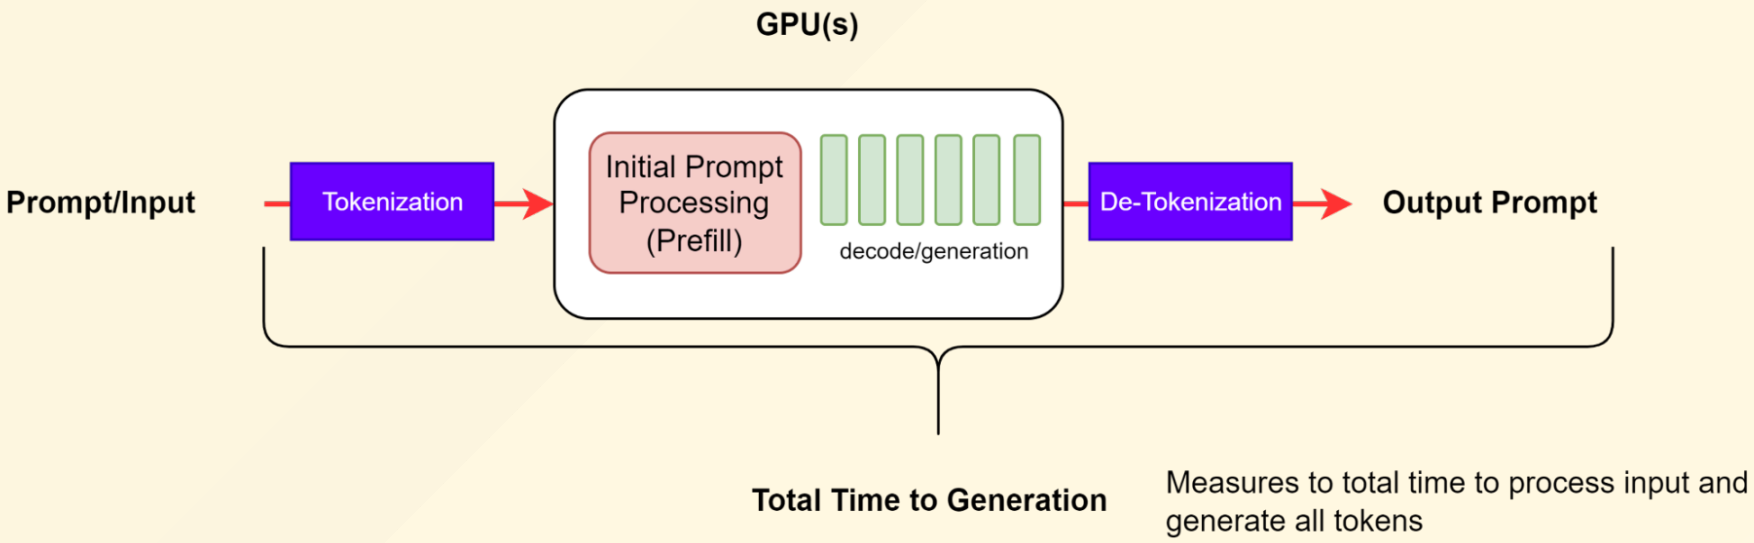

Inter-Token Latency (ITL)

Tempo médio entre tokens consecutivos na fase de **decode**:

$$\mathrm{ITL} = \frac{\mathrm{e2e_latency} - \mathrm{TTFT}}{\mathrm{output_tokens} - 1}$$

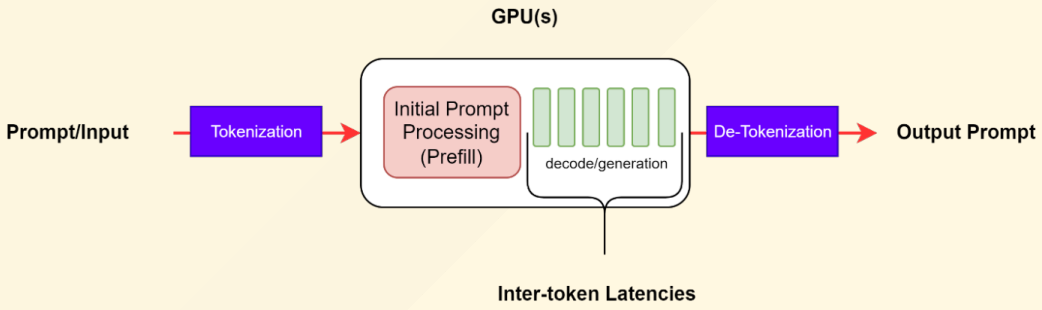

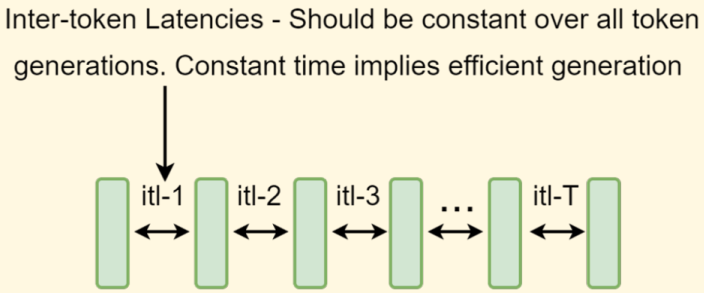

Tokens por Segundo (TPS)

Vazão total do sistema considerando **todos os requests simultâneos**:

$$\mathrm{TPS} = \frac{\mathrm{Total_output_tokens}}{T_y - T_x}$$

Métricas de GPU

Além das métricas de inferência, analisaremos o comportamento **interno da GPU**:

- **SM Occupancy**: Porcentagem dos Streaming Multiprocessors efetivamente usados
- **Memory Bandwidth Utilization** Porcentagem da largura de banda de memória utilizada
- **GPU Memory Usage**: memória alocada durante a inferência

Ferramentas de Benchmark e Profiling

- **GenAI-Perf**: TTFT, ITL, TPS, Latência End-to-End
- **Nsight Systems**: quais kernels rodam, quando e por quanto tempo
- **Nsight Compute**: occupancy, uso de tensor cores, bandwidth
- **nvidia-smi**: utilização da GPU, memória, temperatura e consumo de energia

Tecnologias Utilizadas

- **HuggingFace**: Carregar e executar o modelo Llama 3.1 8B;
- **Nix**: Gerar um ambiente 100% reprodutível para o trabalho;
- **Git**: Versionar todo o ambiente de trabalho;
- **Jupyter Notebooks**: Programação literal da análise dos dados obtidos;
- **Python**: Linguagem de programação usada para escrita da análise dos dados nos Jupyter Notebooks e no particionamento do modelo;
- **Marp**: Criar slides a partir da escrita em Markdown;
- **LaTeX**: Escrita do relatório final.

Referências

- NVIDIA. *LLM Inference Benchmarking: Fundamental Concepts*. https://developer.nvidia.com/blog/llm-benchmarking-fundamental-concepts/
- NVIDIA. *NIM LLM Benchmarking Guide*. https://docs.nvidia.com/nim/benchmarking/llm/latest/index.html
- NVIDIA. *DCGM User Guide — Metrics*. https://docs.nvidia.com/datacenter/dcgm/latest/user-guide/feature-overview.html
- PCAD. https://gppd-hpc.inf.ufrgs.br/